Traitement et modélisation audio

Antony Schutz

Quelques notions de base en analyse spectrale et temporelle

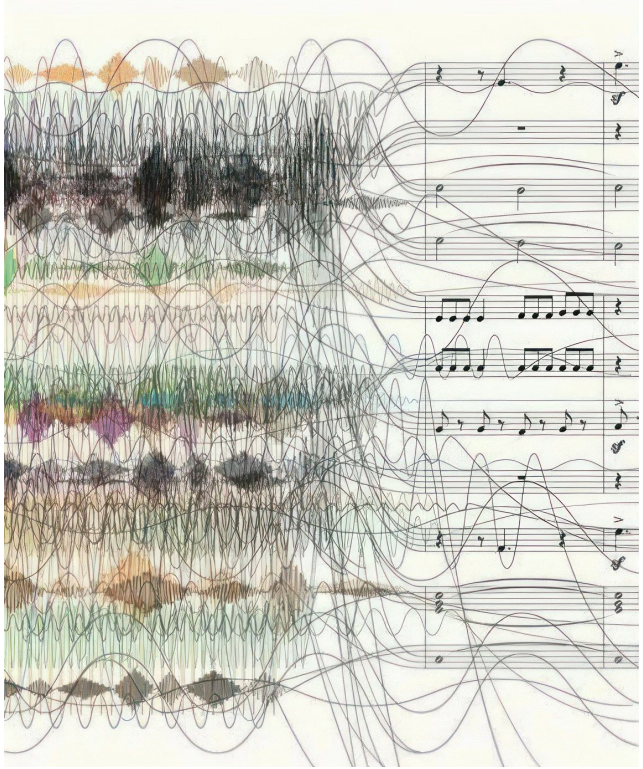
Qu’est ce qu’un son, une musique

Un son est un onde acoustique, c'est-à-dire une vibration mécanique d'un milieu élastique.

La fréquence de ces vibrations est ce que l'on perçoit comme la hauteur du son.

L'intensité du son est quant à elle liée à l'amplitude de la vibration.

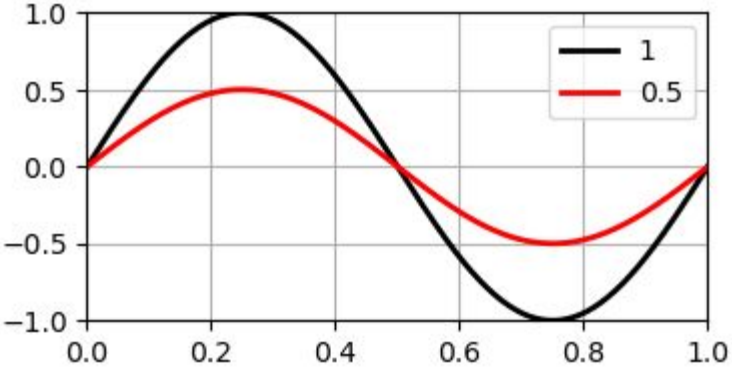
Notre perception des sons est lié à nos capteurs les oreilles et à notre unité de calcul.

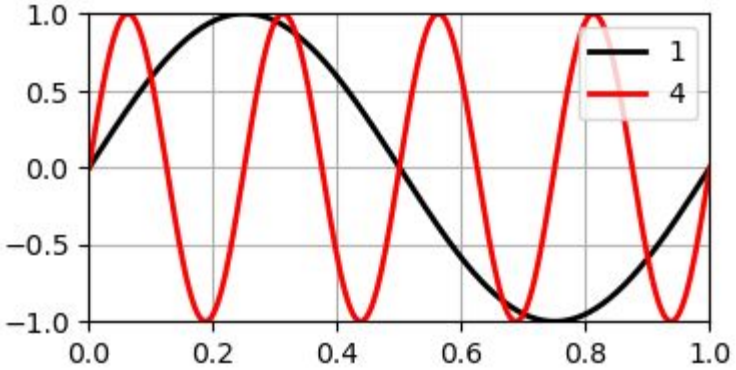


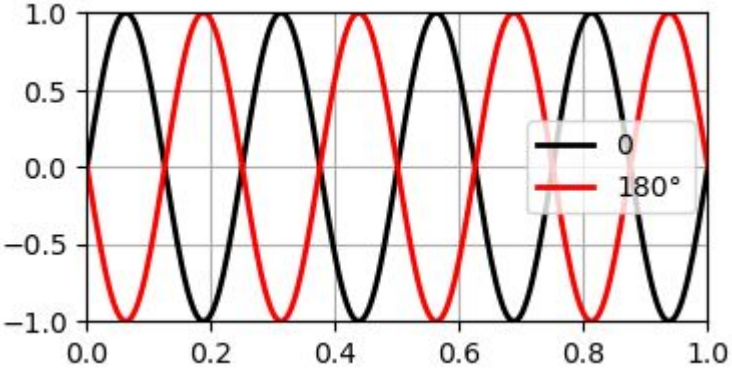
Le modèle sinusoïdal

Le modèle le plus utilisé pour modéliser un son est le modèle sinusoïdal.

On considère qu'un son est composé de plusieurs sinusoïdes d'amplitudes, de fréquences et de phases différentes







Le modèle sinusoïdal

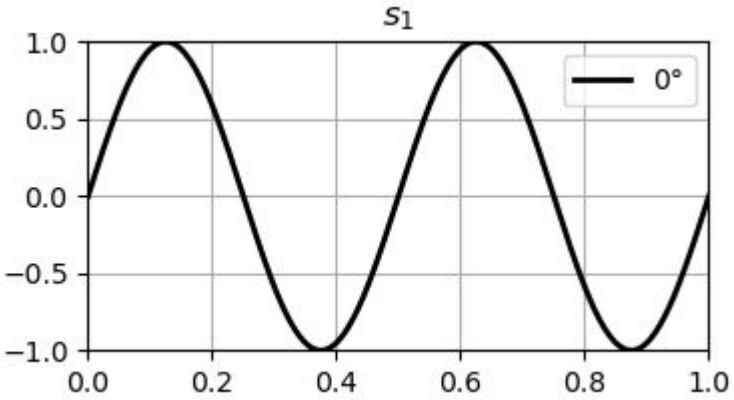
$$s(t) = \sum_m a_m \sin(2\pi\ f_m\ t + \phi_m)$$

$$s_n = \sum_m a_m \sin(2\pi\ f_m\ \frac{n}{F_s} + \phi_m)$$

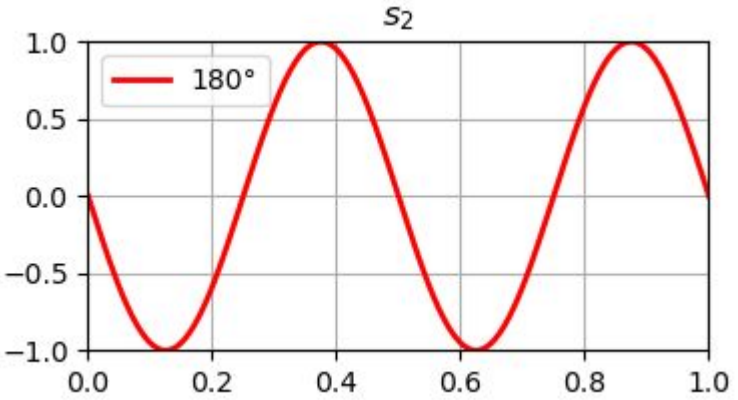
$s(t)$	signal temporel
t	temps
a_m	amplitude de la composante *m*
f_m	fréquence de la composante *m*
ϕ_m	phase de la composante *m*

s_n	signal discret
n	échantillon
F_s	Fréquence d'échantillonnage

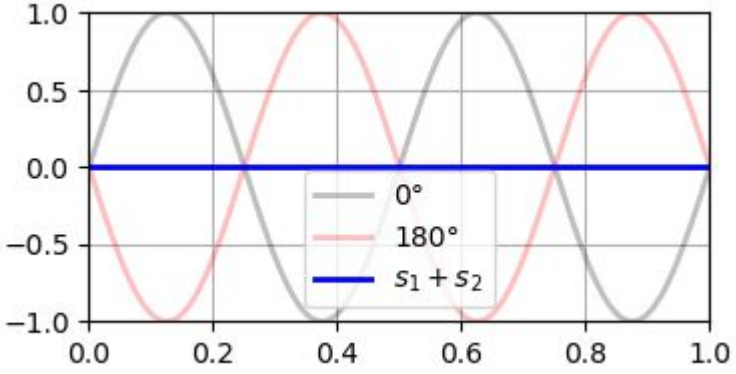
importance de la phase





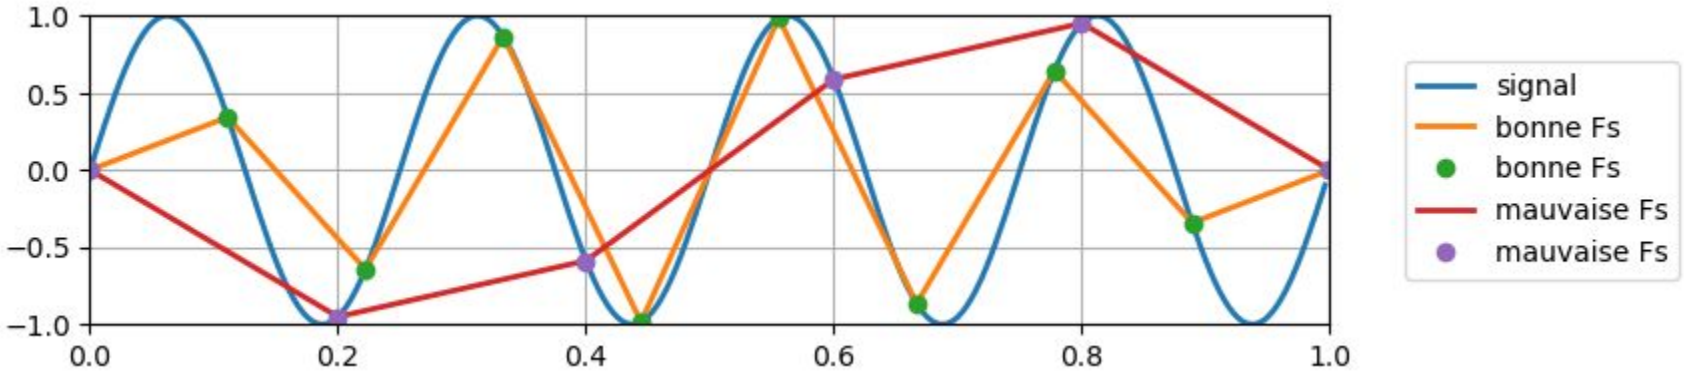






Quand on additionne des sinusoïdes le résultat peut être constructif ou destructif.

importance de la fréquence d'échantillonnage



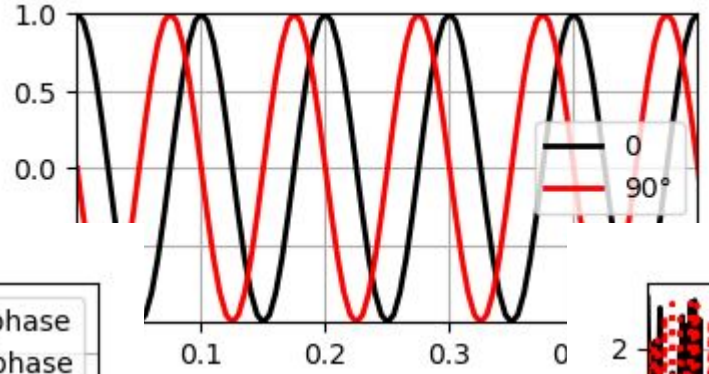
Une mauvaise fréquence d'échantillonnage (trop faible) peut entraîner un échec complet de l'estimation d'une fréquence.

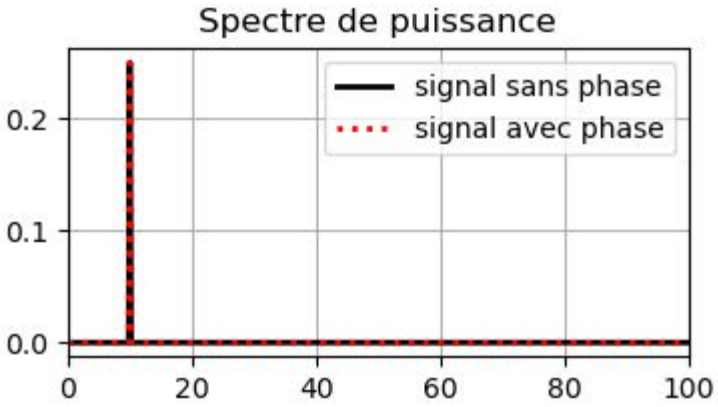
→ **Théorème de Shannon**: la fréquence d'échantillonnage doit être deux fois supérieur à la plus haute fréquence d'un signal

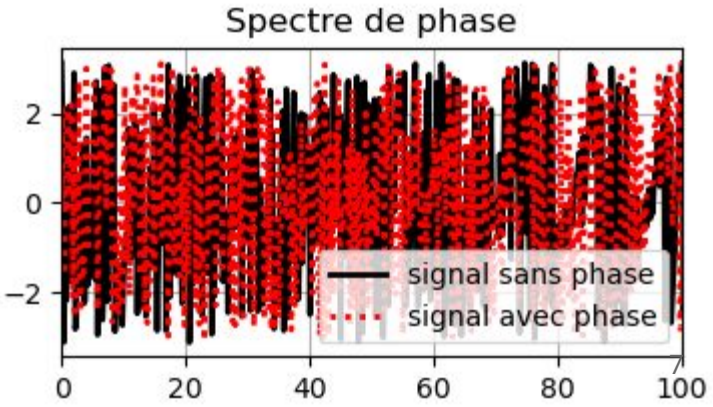
Spectre de puissance et de phase

Le spectre de puissance affiche la puissance des fréquences présentes dans un signal instantané.

Le spectre de phase affiche la phase associé à ces fréquences



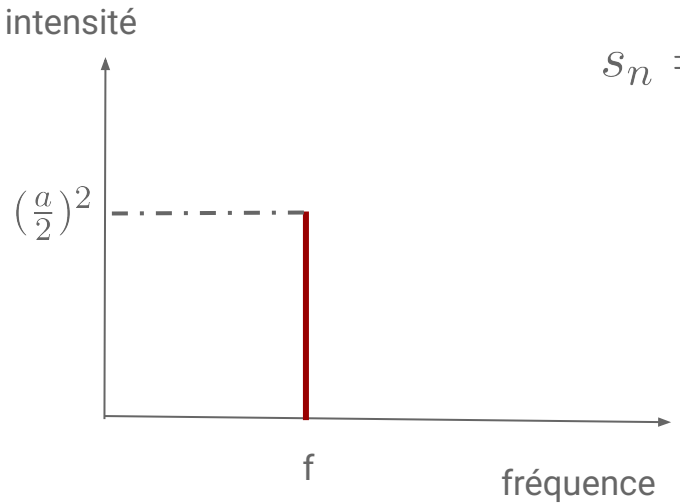




Spectre de puissance et de phase

Le spectre de puissance affiche la puissance des fréquences présentes dans un signal instantané.

Le spectre de phase affiche la phase associé à ces fréquences



$$s_n = \sum_m a_m \sin(2\pi\ f_m\ \frac{n}{F_s} + \phi_m)$$

La phase est beaucoup plus compliqué à comprendre en la regardant, on ne s'y intéressera pas.

Signal harmonique - corde vibrante

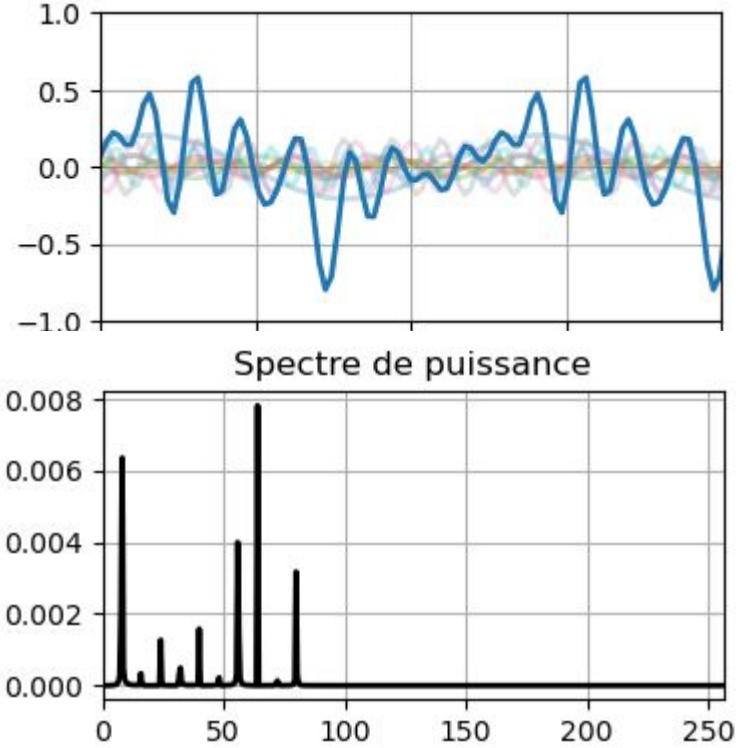
Dans le cas de corde vibrante:

- parole
- instruments à cordes

Un signal harmonique est composé d'une fréquence fondamentale (f0) et d'harmoniques.

Les harmoniques sont des multiples entier de la fréquence fondamentale

$$f_n = n * f_0$$



L’incertitude temps fréquence

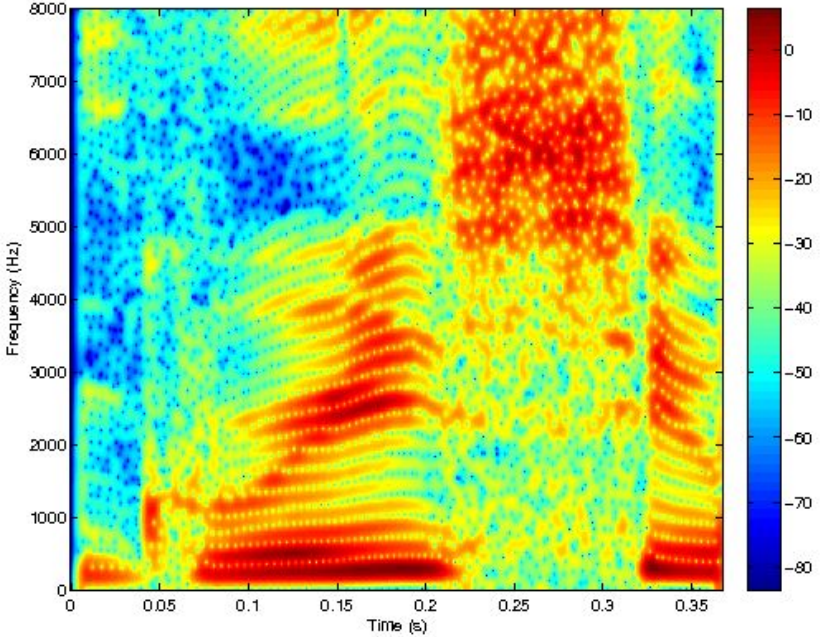
Un spectre est une représentation instantanée du contenu fréquentielle d’un signal.

Un son, comme la parole n’est pas constant dans le temps, le contenu fréquentiel change dans le temps.

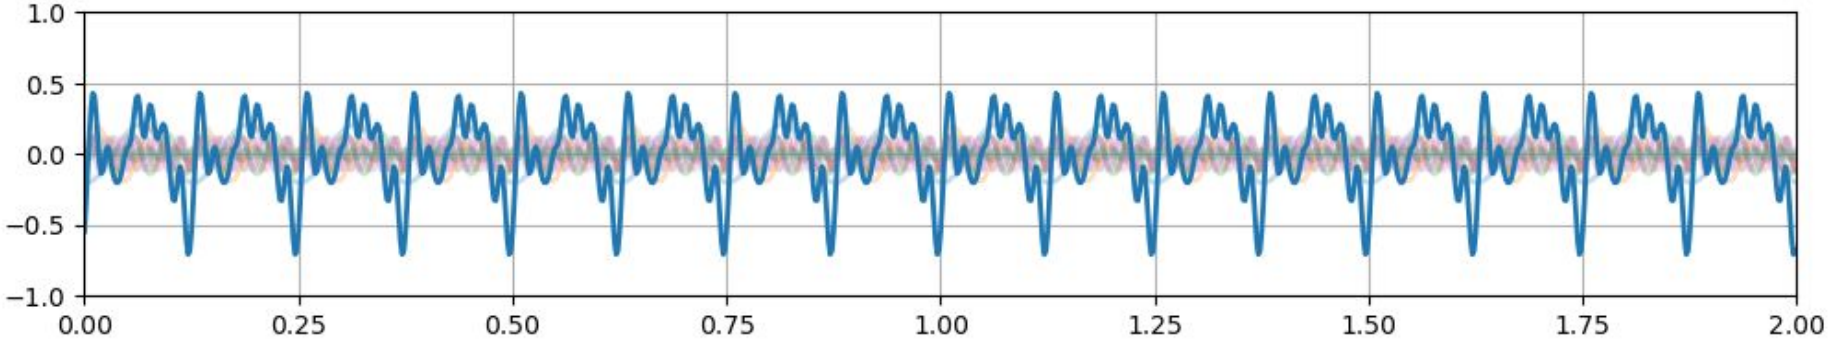
Plus on a une fenêtre de temps qui est longue plus l’estimation spectrale est précise.

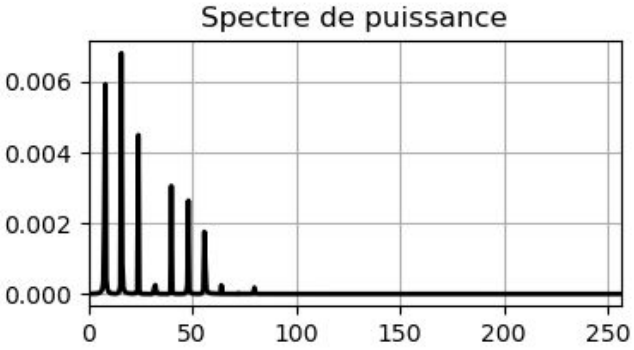
Plus la fenêtre de temps est courte plus on est précis dans le temps et on capte les variations

→ Analyse temps-fréquences



Représentation instantanée






```
5.6,  5.7,  6. ,  6.5,  7.3,  8.4, 10. , 12.3, 15.6, 20.6
```

Un son, comme la parole n’est pas constant

Il y a des silences.

Des mots ou des sons.

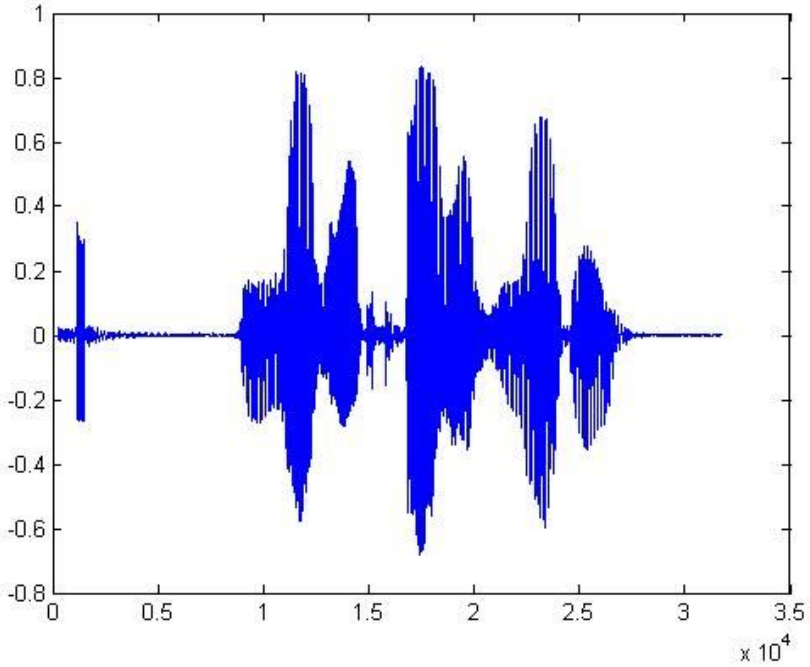
Du bruit extérieur.

Des effets causé par le(s) capteur(s).

Du bruit

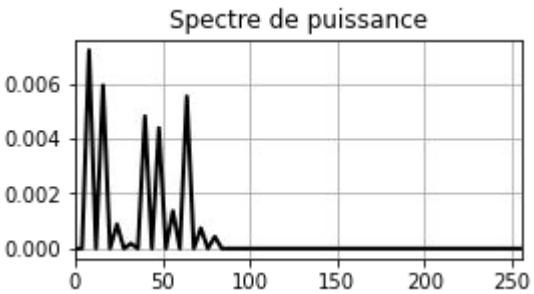
Certains sons ne sont pas périodiques :

- pas de pics de fréquence

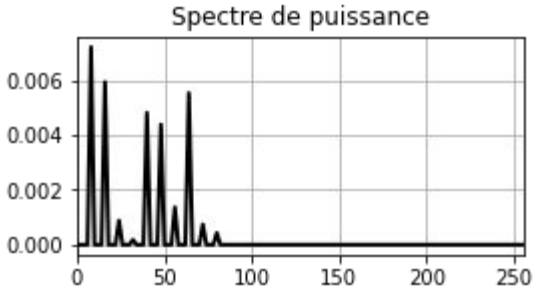


Influence de la durée temporelle

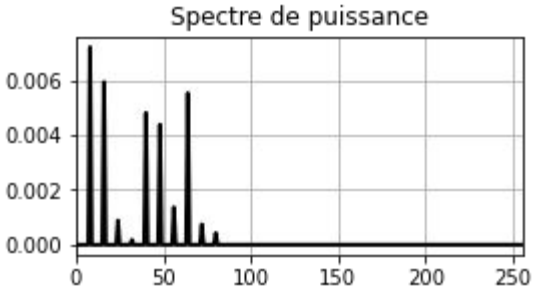
Spectre sur 128 points



Spectre sur 256 points



Spectre sur 512 points



Plus on a de points et plus les pics sont fins et donc précis, le nombre de points défini la précision.

Calculer un spectre et augmenter la résolution

D'un point de vue pratique (pas théorique) un spectre se calcul de la manière suivante pour une fonction continue:

$$S(s) = \|\mathcal{F}(s)\|^2$$

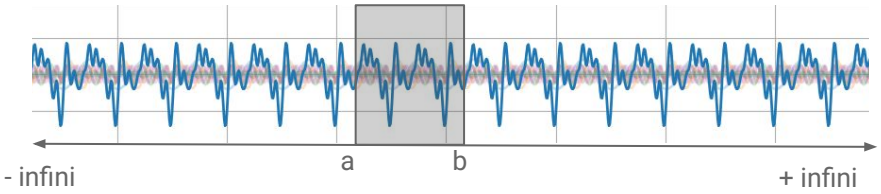
avec

$$\mathcal{F}(s) : \nu \mapsto \hat{s}(f) = \int_{-\infty}^{+\infty} s(t)\, \mathrm{e}^{-2\pi \mathrm{i} f t}\, \mathrm{d}t$$

La transformée de Fourier de la fonction f

Le grand problème de cette transformation, qui est fondamental, est que l'intégrale se calcule de moins à plus l'infini…

En pratique, dans des cas concrets comme l'audio on est donc obligé de limiter l'intervalle entre [a,b]



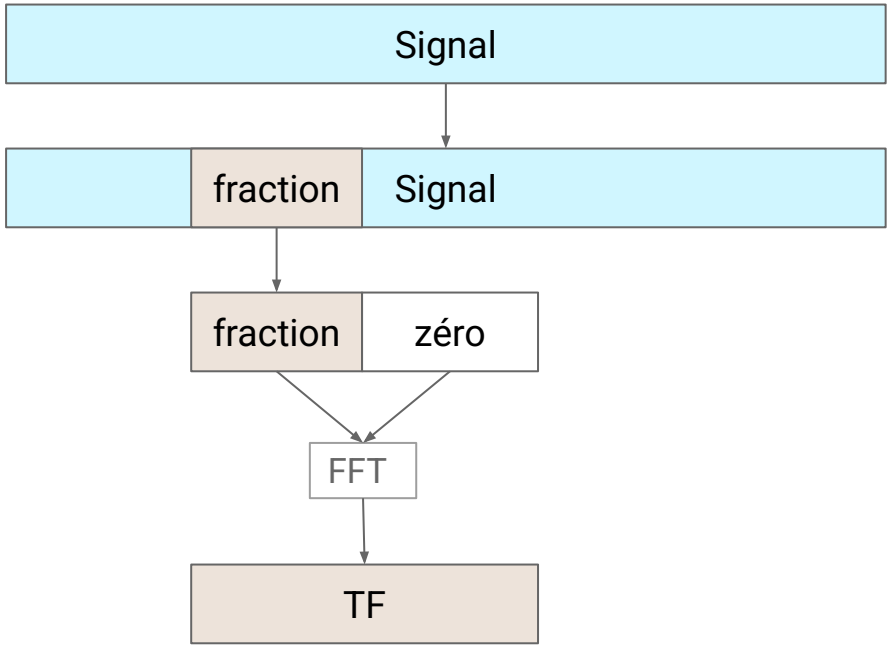
Calculer un spectre et augmenter la résolution

Pour un signal discret on utilisera l'algorithme de transformée de Fourier rapide (Fast Fourier Transform: FFT)

Un paramètre important de la FFT est la valeur du paramètre NFFT et correspond à ce qu'on appelle le zéro padding.

Le zéro padding consiste à ajouter des 0 à la fin du bout de signal pour faire grossir artificiellement le nombre de point.

En conséquence il y a plus de points dans la FFT et la résolution augmente, la précision reste la même.



FFT et convolution

La TF est normalement utilisé pour les signaux périodique mais est fréquemment utilisé sur n'importe quoi de façon à obtenir le spectre.

La transformée de Fourier est donc une astuce pratique pour calculer rapidement un convolution, en utilisant la transformée de Fourier inverse (IFFT)

$$\mathcal{F}^{-1}(\mathcal{F}(f * g)) = f * g = \mathcal{F}^{-1}(\mathcal{F}(f).\mathcal{F}(g))$$

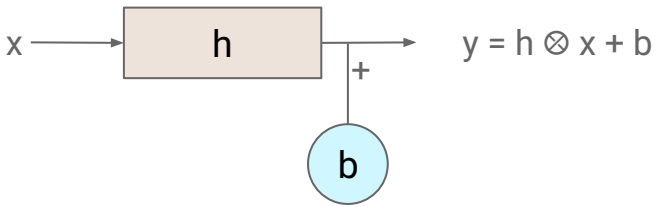
Une propriété admirable de la transformée de Fourier est que la transformée de Fourier d'un produit est égale à la convolution des transformées de Fourier … et vice versa

$$\mathcal{F}(f.g) = \mathcal{F}(f) * \mathcal{F}(g)$$
$$\mathcal{F}(f * g) = \mathcal{F}(f).\mathcal{F}(g)$$

Le résultat d'une fft est nombre complexe, on prendra donc la partie réel du résultat. La fft symétrise le résultat, il faut shifter la partie droite et la partie gauche.

Rappel convolution

Une convolution est l'opérateur qui intervient dans toutes les opérations de filtrage



exemple:

- filtre électronique → antenne, filtre audio
- filtre involontaire → lentille, réverbération
- etc…

Une convolution s'applique sur des fonctions (distributions) et non sur des nombres

Le delta de dirac est l'invariant de la convolution:

$$x = \delta \otimes x$$

C'est l'équivalent:

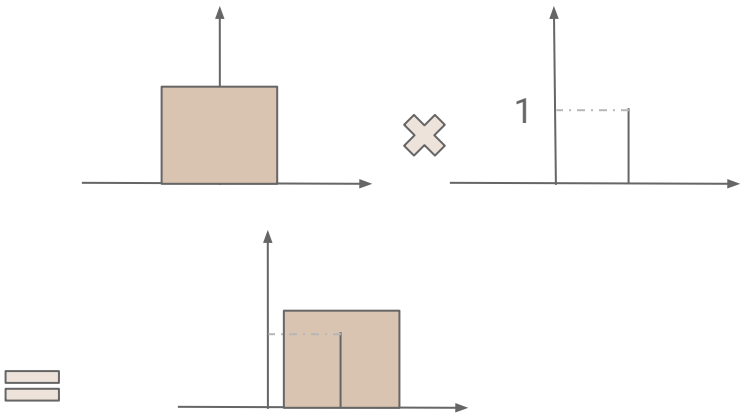
- du 1 pour la multiplication (1*a=a)
- du 0 pour l'addition (0+a=a)
- de l'identité pour les matrices (I*A=A)

C'est une fonction qui vaut 0 partout et l'infini (ou 1) à un seul endroit (infini en continu et 1 en discret)

Rappel de convolution, exemples

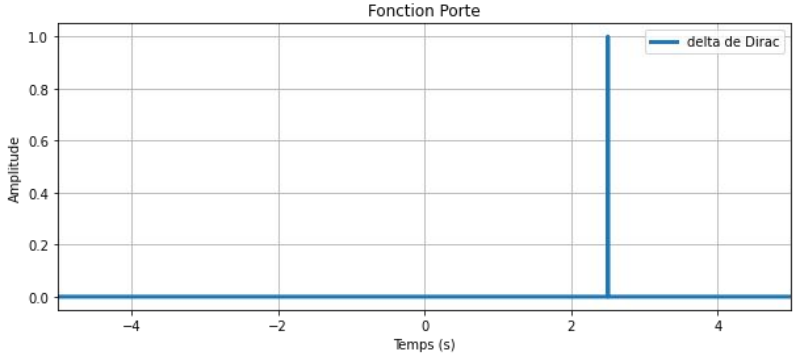
La convolution c'est:

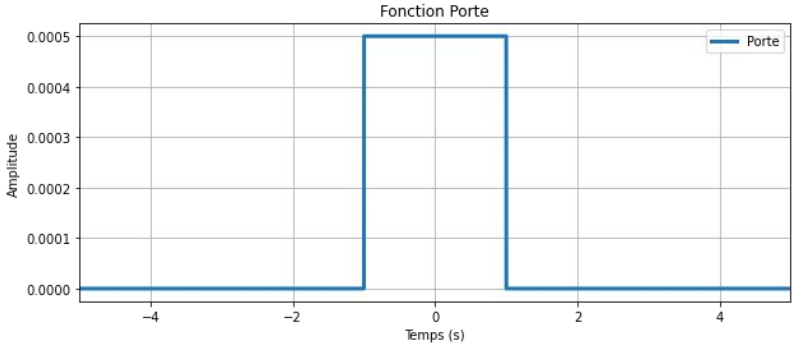
- faire glisser une fonction sur une autre
- a chaque pas on fait le produit des deux
- à ce pas là, la valeur est la somme du produit

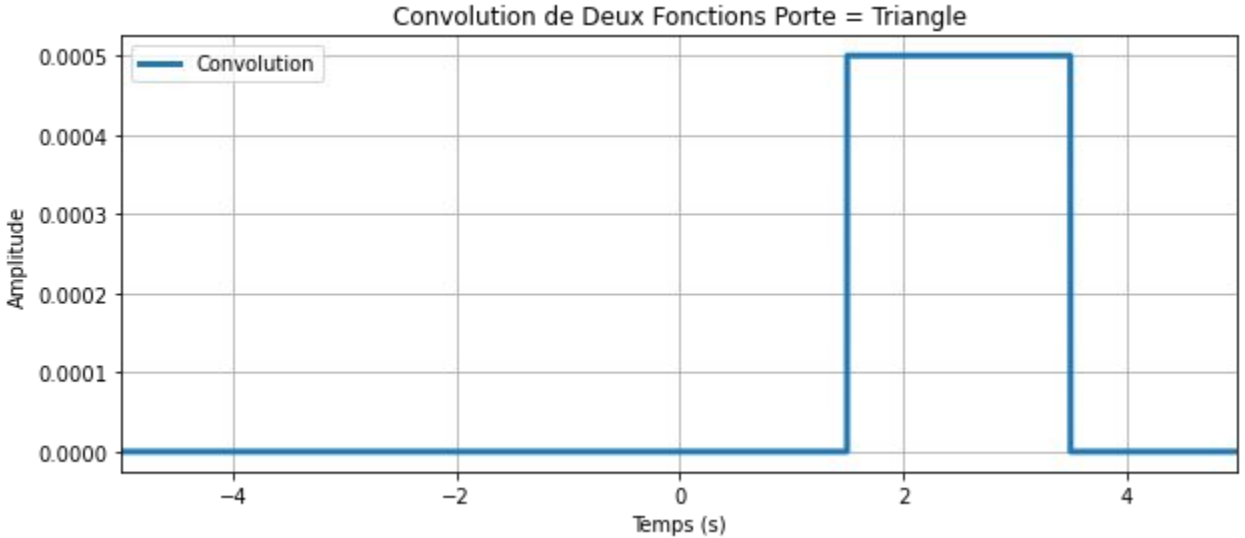


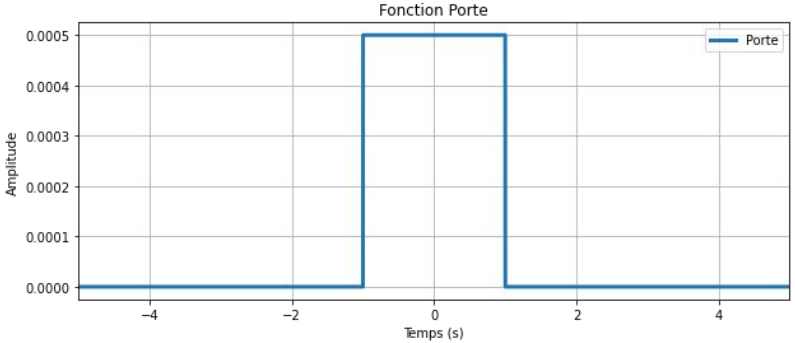
exemples:

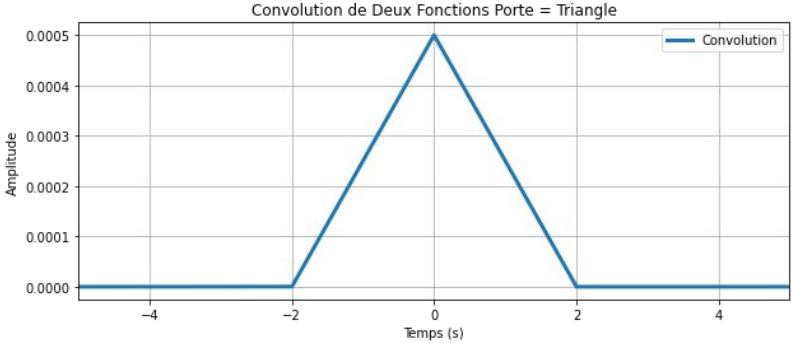
- création d'une fonction porte qui vaut 0 partout sauf dans l'interval (-1,1) et dont la somme vaut 1
- faire une fonction qui calcule la convolution
  - np.fft.fft transformée de Fourier
  - np.fft.ifft transformée de Fourier inverse
  - np.fft.fftshift
  - np.real
- Calculer la convolution d'une porte avec un delta de dirac (0 partout sauf à 1 sample)
- Calculer la convolution d'une porte avec une porte
- sauvegarder le résultat et le convoluer à une fonction porte
- etc...
- regarder le résultat

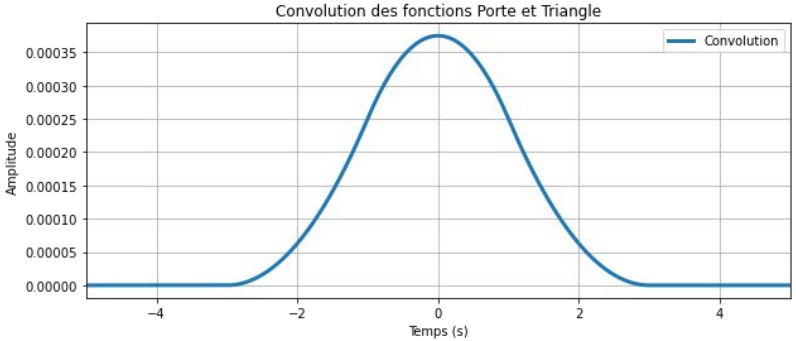

Fonction Porte
delta de Dirac
Amplitude
Temps (s)

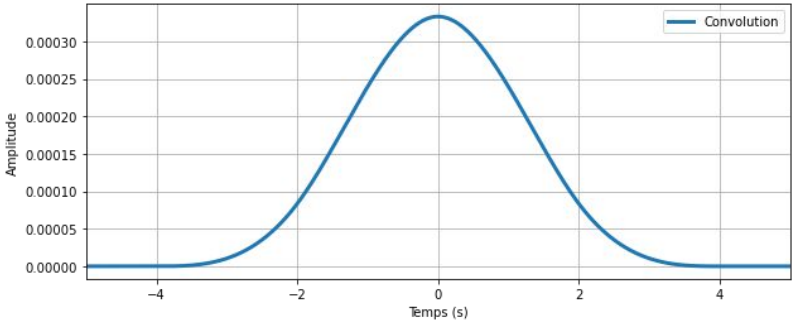

Fonction Porte
Porte
Amplitude
Temps (s)


Convolution de Deux Fonctions Porte = Triangle
Convolution
Amplitude
Temps (s)


Fonction Porte
Porte
Amplitude
Temps (s)
0.0005
0.0004
0.0003
0.0002
0.0001
0.0000
−4
−2
0
2
4


Convolution de Deux Fonctions Porte = Triangle
Convolution
Amplitude
Temps (s)
0.0005
0.0004
0.0003
0.0002
0.0001
0.0000
−4
−2
0
2
4

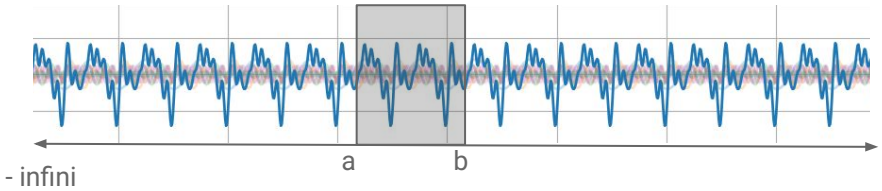

Convolution des fonctions Porte et Triangle
Convolution
Amplitude
Temps (s)
0.00035
0.00030
0.00025
0.00020
0.00015
0.00010
0.00005
0.00000
−4
−2
0
2
4


Convolution
Amplitude
Temps (s)
0.00030
0.00025
0.00020
0.00015
0.00010
0.00005
0.00000
−4
−2
0
2
4

Calculer un spectre et augmenter la résolution

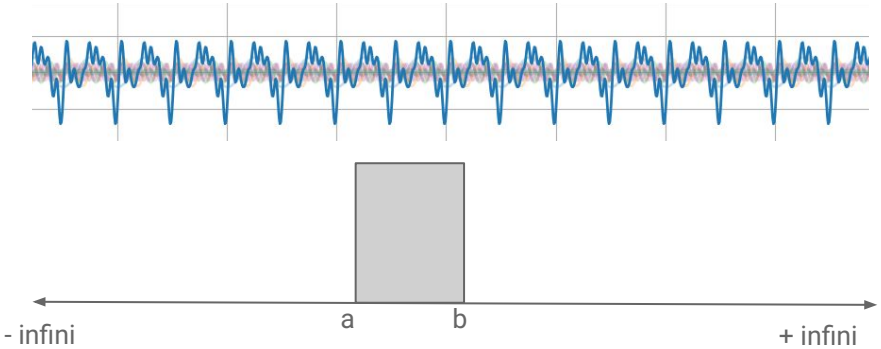
Le grand problème de cette transformation, qui est fondamental, est que l'intégrale se calcule de moins à plus l'infini…

En pratique, dans des cas concrets comme l'audio on est donc obligé de limiter l'intervalle entre [a,b]

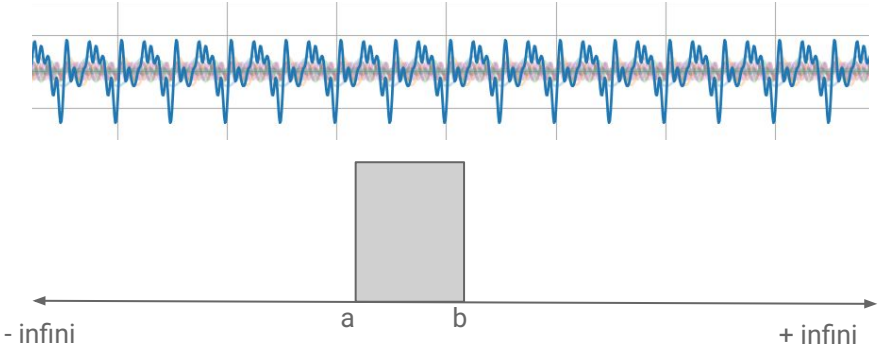


Ce qui signifie littéralement qu'on multiplie deux fonctions (une sinusoïde et une porte)

→ Qu'est ce qui se passe pour le spectre?

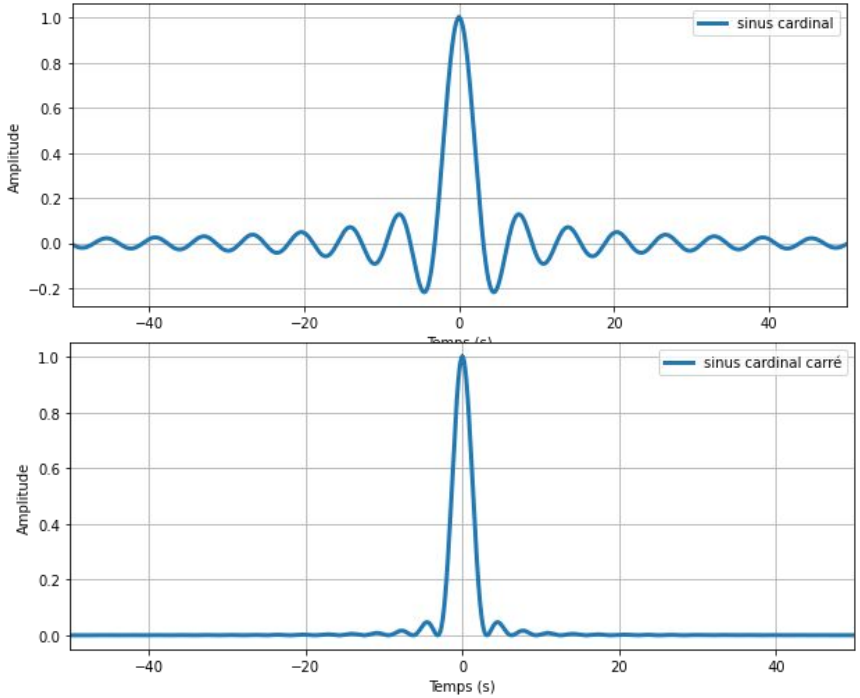


Calculer un spectre et augmenter la résolution



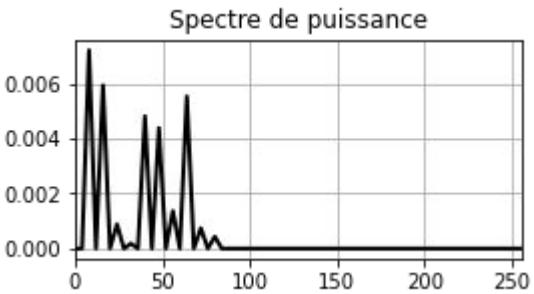
- le produit dans l'espace temporel induit une convolution dans l'espace des fréquences
- convolution de la TF du signal et de la TF de la porte (sinus cardinal)

Fonction sinus cardinal $\mathrm{sinc}(x) = \frac{\sin(x)}{x}$

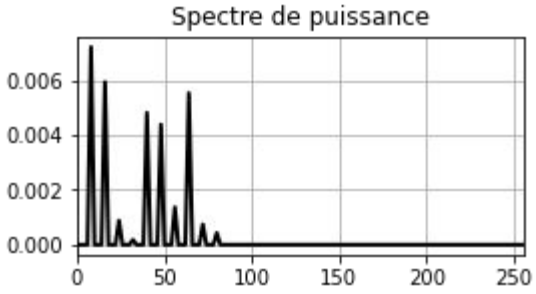


Influence de la durée temporelle

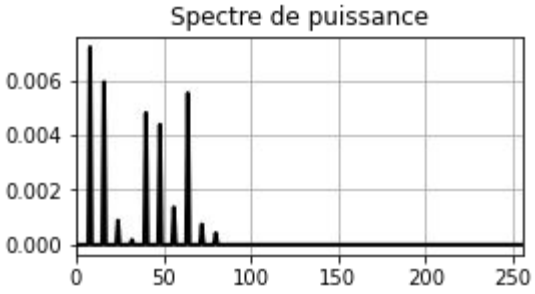
Spectre sur 128 points



Spectre sur 256 points



Spectre sur 512 points



Plus on a de points et plus les pics sont fins et donc précis, le nombre de points défini la précision.

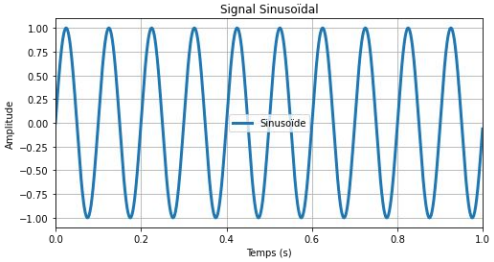
sur une sinusoïde simple

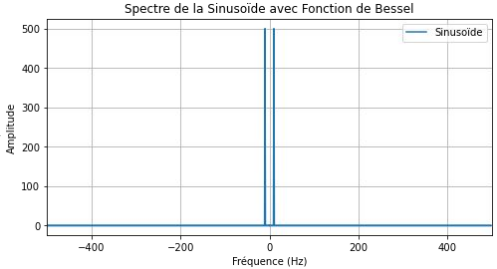
SPECTRE

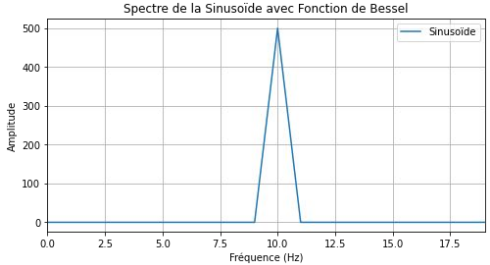
ZOOM

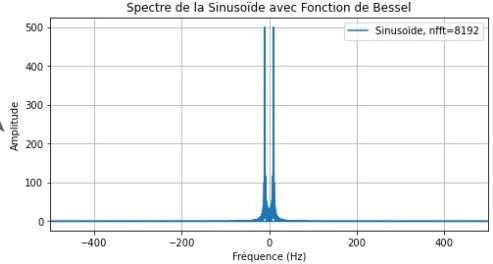
FFT normal

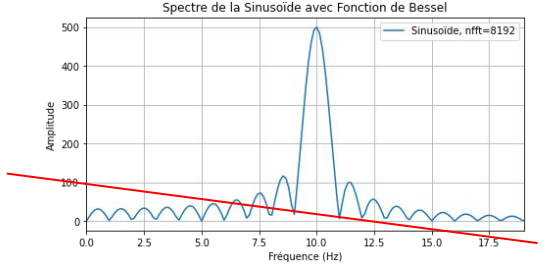
Zéro padding







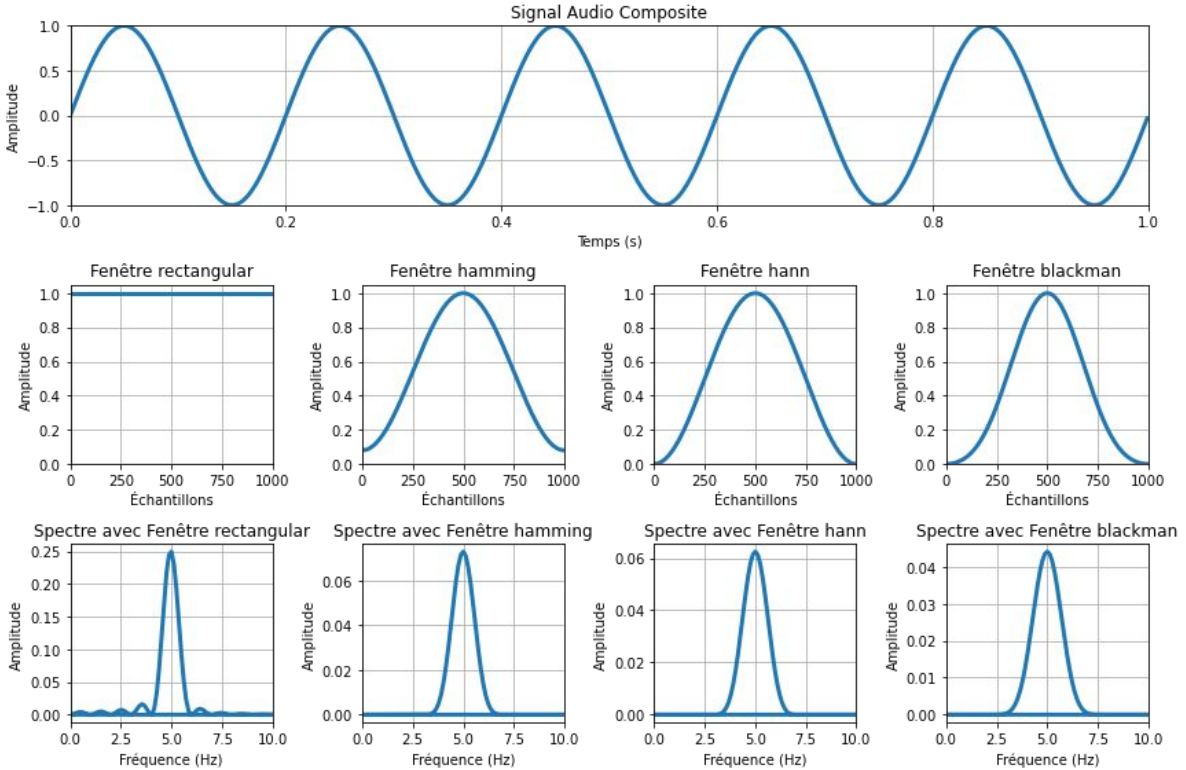




L’impacte de la fenêtre d’analyse

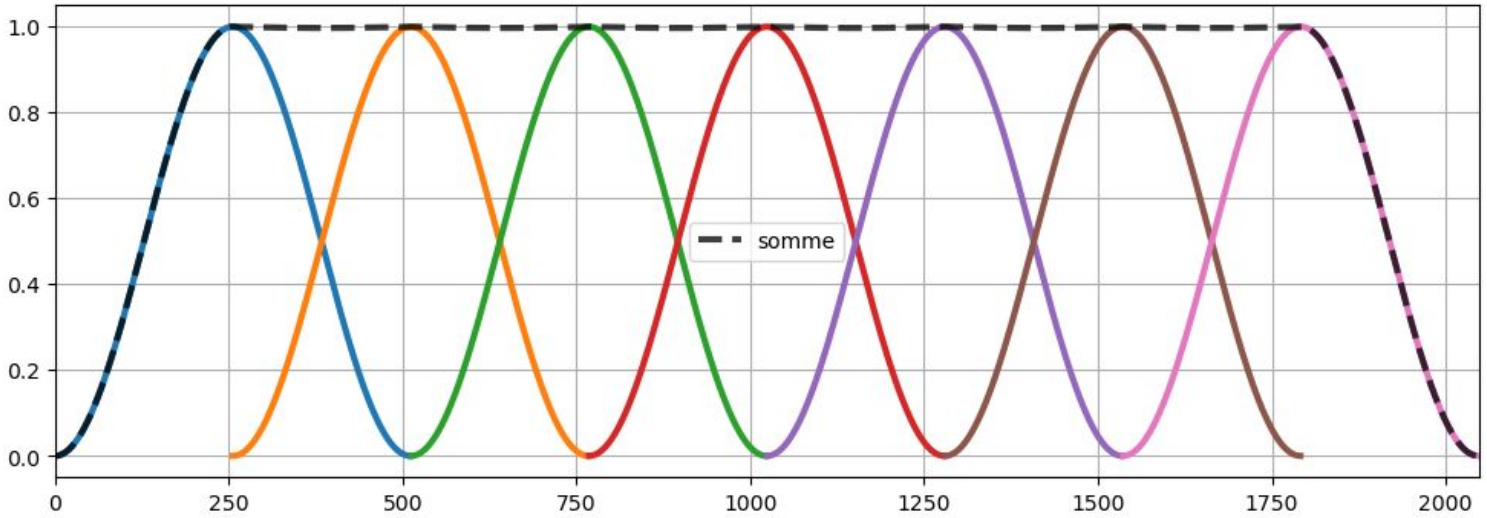
Il existe différents types de fenêtre d’analyse, parmis les plus connues:

- rectangulaire (porte)
- hamming
- hann
- blackman

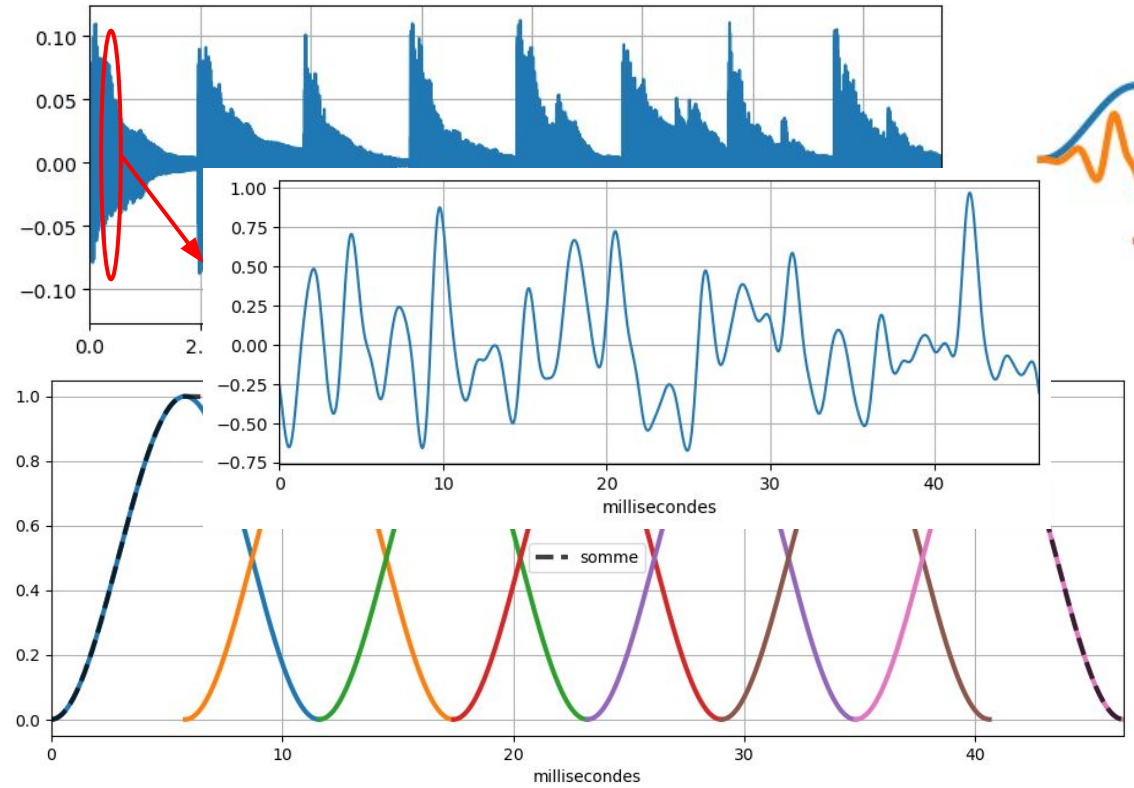


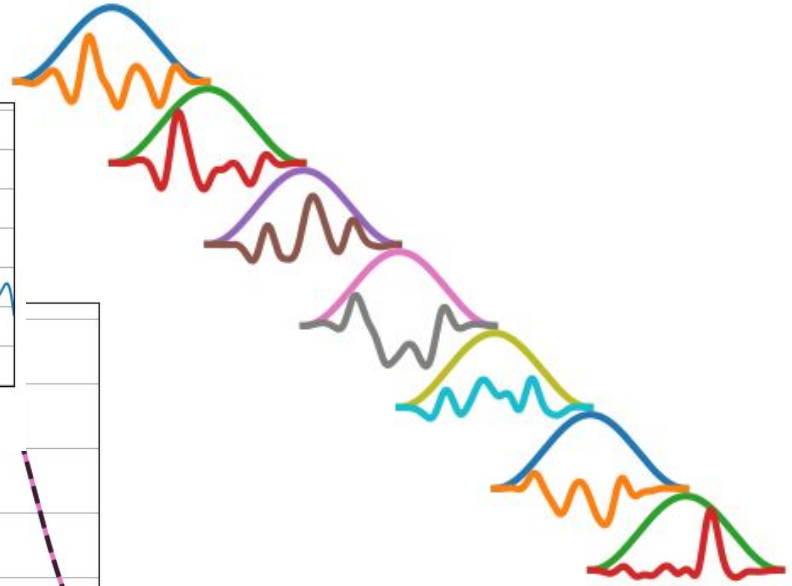
Fenêtre à reconstruction parfaite - overlapping

Afin d'analyser un signal non stationnaire on va le découper en petit bout de signal en utilisant une fenêtre d'analyse à reconstruction parfaite



Analyser un signal non stationnaire





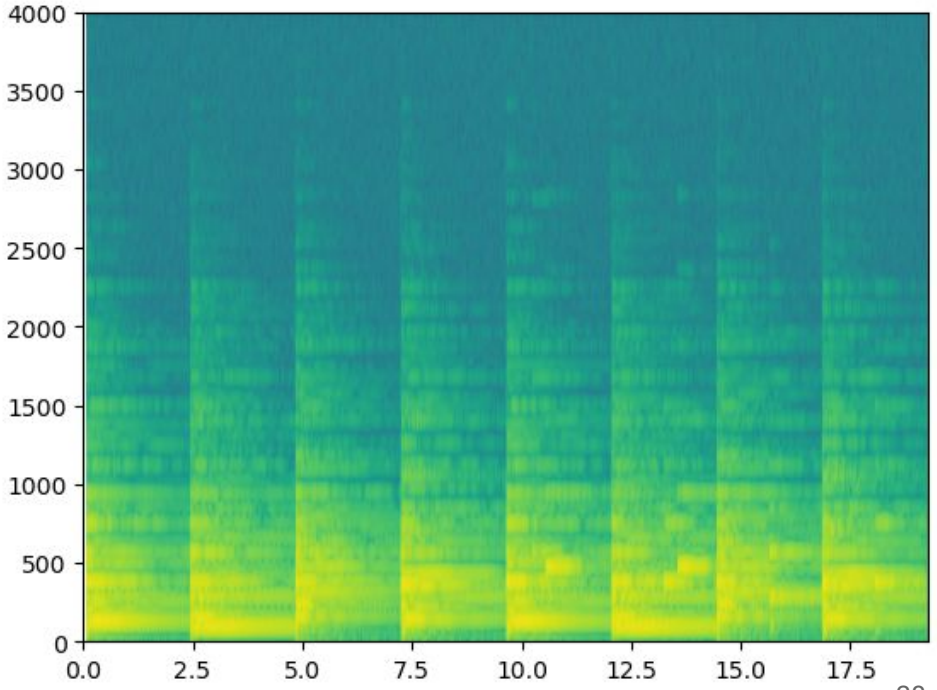
Analyse Temps Fréquence STFT

STFT: Short Time Fourier Transform

La STFT est l'outil de base, le plus simple et le plus rapide de faire de l'analyse temps fréquence.

Consiste à découper le signal non stationnaire temporel en petit morceaux qui se recouvrent. Puis à calculer le spectre de chacun de ces morceaux, cela permet d'avoir une image du contenu Temps Fréquences du signal.

note: on peut faire une FFT (1D) sur un tableau 2D, cela fait la transformée de Fourier sur un seul axe.



Veille technologique

en groupe

- CEPSTRE
- MFCC
- Constant-Q chromagram
- mel-scaled spectrogram
- Modèle Auto regressif (AR Model)

Le processus d'audition se déroule comme suit

Biologiquement

Les sons frappent le pavillon de l'oreille externe.

Les sons sont transmis au tympan par le conduit auditif.

Le tympan vibre.

Les vibrations du tympan sont transmises aux osselets de l'oreille moyenne.

Les osselets transmettent les vibrations à la cochlée.

Les vibrations de la cochlée sont converties en signaux électriques par les cellules ciliées.

Les signaux électriques sont transmis au cerveau par le nerf auditif.

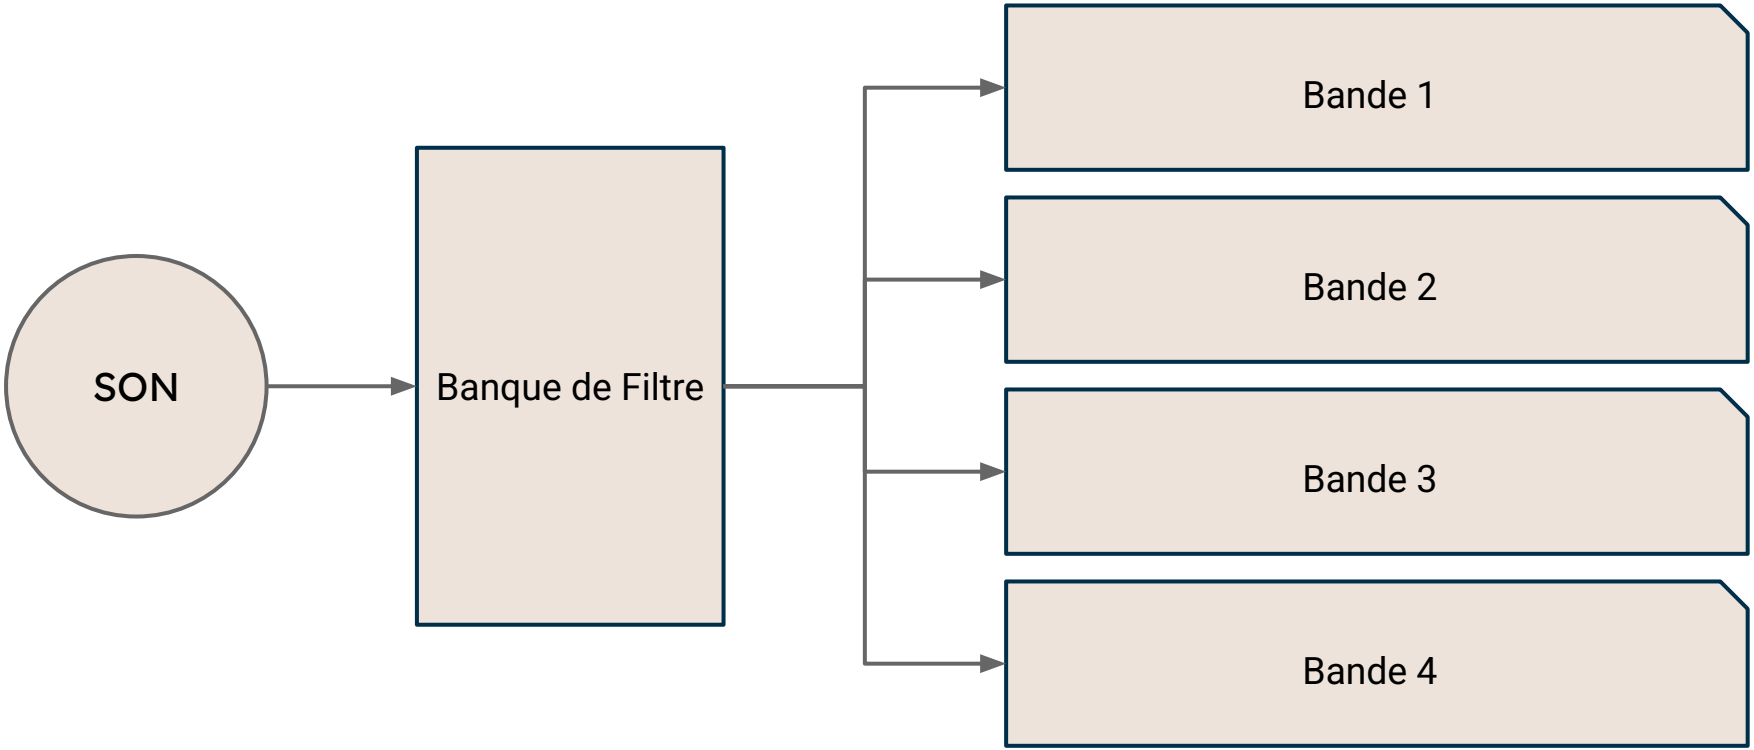
Au point de vue signal

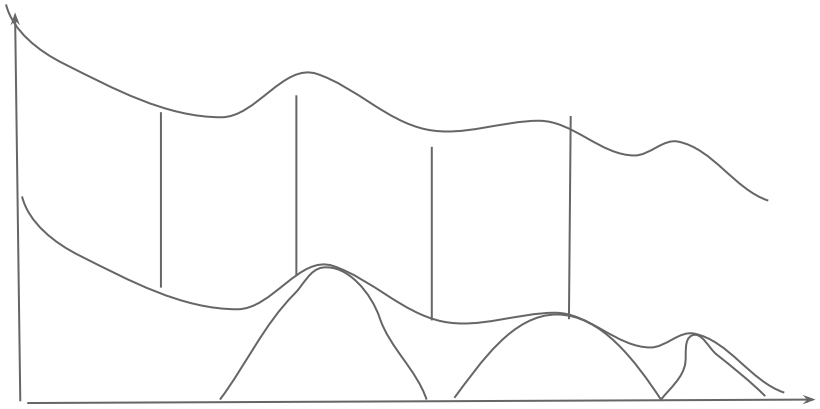
Biologie vers data

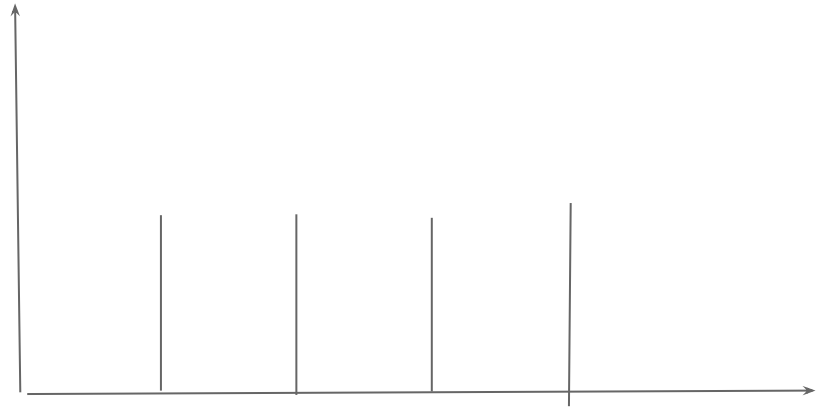
Les cellules ciliées de la cochlée sont disposées en spirale, le long de la cochlée. Les cellules situées à la base de la cochlée sont sensibles aux fréquences basses, tandis que les cellules situées au sommet de la cochlée sont sensibles aux fréquences élevées.

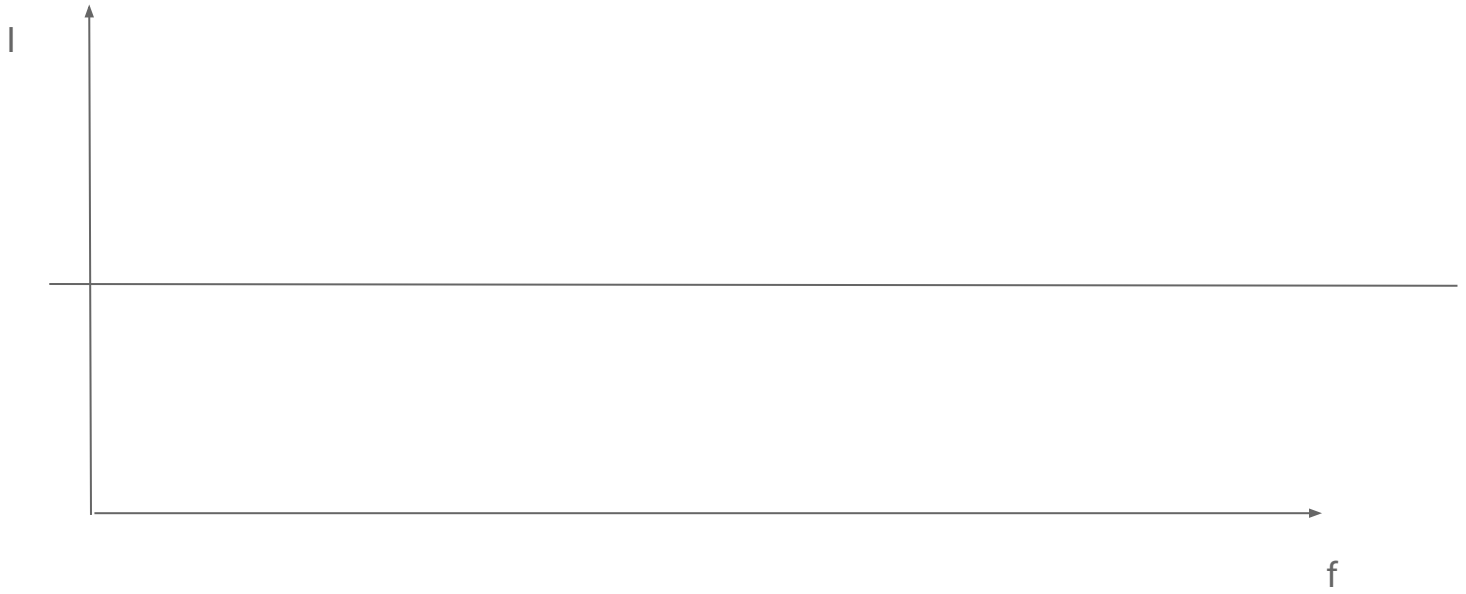
L’oreille se comporte donc un peu comme une banque de filtre

banque de filtre








I
f